

YOLO+時系列モデルによる 進行方向予測

1 班 野川晃輝・青木秀真・岩寄祐希・村中正弘

目次

- 背景
- システムの概要
- 実装の工夫
- 実験結果
- デモ
- 考察
- 今後の展望
- 参考文献

背景

当初の目標：物体検出を用いて「歩行者」の進行方向を予測したい


課題点：

- 歩行者は奥行方向にも動くため、単眼画像から検出した二次元情報だけでは予測が難しいのでは？
- 歩行者の進行方向を予測するためには、一人一人にモデルを適用する必要があり、計算量が膨大になるのでは？

最終目標：

単眼画像から深度を推定した上で「自分」が進むべき方向を予測する！

システムの概要



データセットの前処理

- JRDB データセットを使用

- ロボ(右図)で撮影した単眼画像
- 画像から検知した人間の box 情報



\(・ω・\)


- box 情報を使って正解データを作成

- 画像を八つのエリアに分割
- box の幅から混み具合を計算
- 空いてる場所を正解とする確率分布を作成



奥行き推定

- **Depth-Anything-V2** を使用
 - **単眼画像**から相対深度を推定するモデル
- **絶対深度 (m)** を推定できるようにfine tune
 - **NYU Depth Dataset V2** データセットを使用
 - encoderは凍結、decoderと追加層を学習 ⇒ 既存の重みデータの精度を活かす



特徴量抽出・概要

- YOLO v8 を使用
 - 2023年発表の物体検出に特化したモデル
- 特徴量
 - 人物を囲む矩形の座標
 - 人を識別するID
 - 矩形の信頼度
 - 骨格ポイントの座標
 - ポイントの信頼度



信頼度

ID	人間	鼻	左目
1(中央)	0.9040	0.9747	0.7999

特徴量抽出・実装の工夫

- 人物領域の除外


- 背景の動きから自分の動きを逆算する時に活用
- 人の矩形は除去して背景の動きを計算

- 外れ値の除外

- 揺れる木やノイズを考える時に活用
- 多数決の結果から大きくずれた値は除去



モデルの設計




入力

入力テンソル [B, T, N, F]

- B ... バッチ数: 同時に処理する時系列サンプル数
- T ... 過去フレーム長: 予測に使用する過去フレーム数
- N ... 1フレームあたりの最大人数: 特徴抽出の最大対象人数
- F ... 1人あたりの特徴量: 位置、方向ベクトル、骨格ポイント、etc

設計の工夫

人物特徴エンコーダ: 人物ごとの特徴を共通埋め込みに揃える




入力される特徴(位置、関節の情報、信頼度、etc)はスケールや意味がバラバラ

→非線形MLPにより特徴量を比較可能な潜在表現へ変換

設計の工夫

注意機構による集合プーリング: 可変人数を学習可能な重み付き平均で集約


- 時刻 t の N 人分の表現を1本のベクトルに変換
- 「誰が重要か？」を学習して重み付きで平均



設計の工夫

時系列エンコーダ①: 順序の情報を持ったTransformer


- 位置エンコーディング
 - 系列に順番の情報を与える
- Transformer Encoder
 - 自己注意機構により全時刻を参照して、フレーム間の重要度や関係を拾う



設計の工夫

時系列エンコーダ②: GRUモデル


- GRU: LSTMの軽量版
 - 計算コストが比較的軽い
- 入力・忘却ゲートを更新ゲートにひとまとめ
 - ゲート数減少により効率↑
- リセットゲートを導入
 - 不要な情報を除去する仕組みを簡素化



設計の工夫

分類ヘッド: 入力をK個のクラスのスコアに変換

- LayerNormによって正規化
- GELUを挟んだMLPによる非線形なクラス分離
- Dropout層による過学習の抑制



実験結果

Top1-accによる精度評価

正答率: **69.18%** (Transformer使用)

- 8エリア分割なので、適当に選んだ場合は 12.5%
 - ただし正解データはone-hotではないソフト分布
- 数字よりも性能が低い可能性がある
 - 学習データでは人が過度に密集しているわけではない
 - 複数の正解エリアがある中で、3割も外してしまっている

デモ動画



結果を受けて

- decoder変更: 残渣予測層を追加
 - 元の学習データをfine-tune ⇒ 正答率:60.7%
 - 残渣予測層を多層化+fine-tune ⇒ 正答率:60.7%
 - 多層化+最初から学習 ⇒ 正答率:64.7%
- encoder変更: 人物特徴エンコーダを改修
 - LayerNorm + Dropoutを更に追加 ⇒ 正答率:38.8%
 - 学習が進みきらずに終了した可能性

今後の展望

- データセットの充実
 - 深度推定のfine-tuneに使用したデータセットは 1500ペア程度
 - モデル学習に使用したフレーム画像は約 70000枚程度
 - 人間が十分に写っていない画像も多い
- モデル構造の試行錯誤
 - GRUやtransformer以外のencoder
 - social-STGCNN
 - decoderの多層化やencoderとの接続
 - 損失関数や学習率の検討
- 地形情報や現在の立ち位置の考慮
 - 人の情報のみを考慮しているため、壁や段差などを認識していない
 - 画面中央や奥行がある場所ほど有利になるように正解データを作る

参考文献

- データセット
 - https://cs.nyu.edu/~fergus/datasets/nyu_depth_v2.html
 - <https://jrdb.erc.monash.edu/>
- 歩行者がどこにいるかの予測
 - <https://arxiv.org/pdf/1711.11217>
- 人物の奥行きとその信頼区間の予測
 - <https://arxiv.org/pdf/1906.06059>

Thank you for your attention!